天津大学

课程实验报告



题目：基于多源海洋监测数据的盐度变化规律分析与预测

学　　院	人工智能学院
专　　业	人工智能
年　　级	**24 级**
姓　　名	卢思宇
学　　号	**3024244246**
指导教师	王煜

摘　　要

本实验面向真实海洋环境监测场景，围绕“盐度变化规律分析与预测”这一核心问题，使用海流、波浪、水质、气象与设备状态五类异构监测数据，构建了多源数据融合、分颗粒度建模与结果解释的一体化分析流程。针对真实数据中普遍存在的异步采样、缺失值与异常值问题，本文以水质表为锚点，按 ZDMC + DataTime 建立多表左连接，结合物理范围约束、分类型缺失处理与时间周期特征编码，形成可用于监督与无监督任务的统一样本。建模策略遵循“先小颗粒度、再大颗粒度、最后结构解释”的路径：先在小时级建立线性回归基线，再在天级聚合数据上进行对比建模，并使用时间序列交叉验证选择 Ridge 正则强度，最后通过 KMeans 聚类识别环境状态类型并分析其物理特征差异。

实验结果表明，在严格的“历史训练—未来测试”设置下，Ridge 回归在小时级与天级均优于普通线性回归，小时级最佳模型取得 RMSE=8.793、MAE=3.669，天级最佳模型取得 RMSE=12.738、MAE=6.013，说明正则化在线性体系内对多源高噪声数据具有显著稳健化作用。聚类结果显示最优簇数为 2（silhouette=0.277），尽管簇间分离度中等，但仍揭示了样本在盐度、浊度、风速和流速上的结构差异，为回归误差来源解释提供了辅助证据。综合来看，本实验在课程已学方法框架内实现了从数据治理到模型评估、从数值预测到规律解释的完整闭环，结果具有可复现性与分析价值。

关键词：海洋环境监测，多源数据融合，盐度预测，Ridge 回归，时间颗粒度，聚类分析

目　录

第一章　介绍、数据与预处理 1
1.1　介绍（5 分） 1
1.2　数据说明与问题定义 1
1.3　多源数据整合、预处理与关键代码（10 分） 2
1.3.1　数据整合策略 2
1.3.2　清洗规则与异常处理 2
1.3.3　特征工程与时间颗粒度构造 2
1.3.4　缺失处理、编码与防泄漏 3
第二章　算法设计与结果分析 4
2.1　算法选择与设计（45 分） 4
2.1.1　任务定义与方法选择合理性 4
2.1.2　流程设计与实现细节 4
2.2　结果分析与可视化（15 分） 4
2.2.1　小时级回归结果 4
2.2.2　天级回归结果 6
2.2.3　聚类结果与状态解释 6
2.2.4　补充可视化 8
2.2.5　本章小结 8
第三章　讨论、结论与 AI 辅助说明 10
3.1　开放性思考与讨论（20 分） 10
3.1.1　跨时间分布漂移导致泛化压力增大 10
3.1.2　多源异步采样带来的信息不对齐 10
3.1.3　异常值中信号与噪声的边界不清 10
3.1.4　线性模型的可解释性与表达上限 10
3.1.5　多指标联合解读的重要性 10
3.1.6　可复现性是实验质量的关键 11
3.2　结论（5 分） 11
3.3　AI 辅助分析与算法改进说明（附加分，最高 10 分） 11
参考文献 12
附　录 13
附录 A　复现实验命令 13

附录 B　主要输出文件说明 13
附录 C　说明 13

第一章　介绍、数据与预处理

1.1　介绍（5 分）

本实验面向真实海洋环境监测业务数据展开，核心目标是基于多源观测信息分析盐度变化规律并完成预测。海洋环境变化由海流输运、波浪扰动、气象驱动、水质演变以及设备状态共同作用决定，单表分析通常只能得到局部结论，难以支持稳定建模与规律解释。课程实验将该类真实数据作为训练对象，本质上是将机器学习方法应用到“高噪声、多约束、异步采样”的工程场景中[1-2]。

结合课程要求与评分维度，本文采用“先小颗粒度、再大颗粒度、最后结构解释”的路线：先建立小时级回归基线，再进行天级聚合回归对比，最后通过聚类识别环境状态差异。该路线对应了“任务定义、方法流程、结果解释与反思”的完整闭环，并保证每一步都可由输出文件复核。

1.2　数据说明与问题定义

实验数据包含训练集与测试集，每个集合均由五张监测表组成：海流、波浪、水质、气象、设备状态。各表通过站点标识 `ZDMC` 与采样时间 `DataTime` 关联。融合后的训练集样本量为 39472 条，时间范围为 2023-02-23 15:00:00 至 2025-07-24 19:00:00；融合后的测试集样本量为 9869 条，时间范围为 2025-07-24 20:00:00 至 2026-04-08 19:00:00。该划分满足“历史训练、未来测试”的严格时序外推评估。

本文设置一个主任务与一个辅助任务：

- 主任务：监督学习回归，利用多源特征预测盐度 `Sal`，评价指标为 MAE、RMSE、R^2；
- 辅助任务：无监督聚类，在天级特征空间识别环境状态类型，并分析簇间物理差异。

需要强调的是，本实验优先以盐度预测为主线。原因在于盐度标签可用性更高，能够保证建模链条稳定；营养盐相关内容在讨论部分作为机制拓展进行补充。

1.3 多源数据整合、预处理与关键代码（10 分）

1.3.1 数据整合策略

多源整合采用“水质表锚定 + 其余四表左连接”策略：以 03. 水质数据作为主表，其他来源按 ZDMC + DataTime 左连接。该方案将监督任务可用性作为优先目标，在不牺牲标签可用性的前提下最大化保留外部特征信息。

```
anchor_file = next((f for f in files if "03." in f.name), files[0])
merged = read_table(anchor_file)
for file_path in other_files:
    df = read_table(file_path)
    merged = merged.merge(df, on=["ZDMC", "DataTime"], how="left")
```

Listing 1.1 以水质表为锚点的多源左连接

1.3.2 清洗规则与异常处理

考虑到真实监测数据存在设备噪声和突发工况，本文采用“字段级约束 + 缺失化处理”：对明显违反物理范围的观测值，仅将对应字段置为缺失，不直接删除整条样本。规则包括：pH$\in[0,14]$，Sal$\in[0,45]$，TDS_ppt≥ 0，DO_ppm≥ 0。该策略减少了非法值对模型的污染，同时尽量保留其余可用特征。

此外，统一将 DataTime 转换为时间戳，删除主键缺失样本，并按 ZDMC + DataTime 去重，保证样本唯一性与评估公平性。

1.3.3 特征工程与时间颗粒度构造

为表达周期性,本文在 hour/dayofweek/month 基础上加入正余弦编码(hour_sin/hour_cos month_sin/month_cos)，以避免周期边界断裂问题。核心代码如下。

```
out["hour_sin"] = np.sin(2 * np.pi * out["hour"] / 24.0)
out["hour_cos"] = np.cos(2 * np.pi * out["hour"] / 24.0)
out["month_sin"] = np.sin(2 * np.pi * out["month"] / 12.0)
out["month_cos"] = np.cos(2 * np.pi * out["month"] / 12.0)
```

Listing 1.2 周期时间特征构造

颗粒度设置分为两层：小时级用于基线回归；天级按 ZDMC + date 聚合均值、标准差、最小值和最大值，用于稳健性对比与结构解释。

1.3.4 缺失处理、编码与防泄漏

建模采用 `Pipeline + ColumnTransformer`：数值特征中位数填补并标准化，类别特征众数填补并 One-Hot 编码。天级阶段显式删除 `Sal_*` 同日统计列，防止目标泄漏，关键代码如下。

```
leak_cols = [c for c in X.columns if c.startswith("Sal_")]
if leak_cols:
    X = X.drop(columns=leak_cols)
```

Listing 1.3　天级建模的目标泄漏防护

上述流程对应评分中的“多源对应关系说明、预处理方法说明、关键代码呈现”三项要求，且与后续模型结果保持因果一致[3]。

第二章　算法设计与结果分析

2.1　算法选择与设计（45 分）

2.1.1　任务定义与方法选择合理性

本实验在课程已学方法范围内，选择 `LinearRegression` 与 `Ridge` 完成监督回归对比。线性回归作为可解释基线，Ridge 用于缓解多源特征条件下的共线性与噪声放大问题，其目标函数中 L2 正则项可提升参数稳定性与泛化能力[4-5]。

辅助任务采用 KMeans 聚类。该任务不直接参与盐度回归训练，而是用于识别环境状态簇并解释误差来源，形成“预测 + 解释”的联动分析框架。

2.1.2　流程设计与实现细节

整体流程为三层：

- 小时级回归：建立原始时间分辨率基线；
- 天级回归：对比时间聚合后噪声抑制与信息损失；
- 聚类分析：在天级特征空间做结构解释。

为保证评估真实性，训练与测试严格按时序划分，不做随机打散。Ridge 参数在训练集内使用 `TimeSeriesSplit` 进行时间序列交叉验证，候选 `alpha` 为 {0.1, 1, 10, 100}，最终小时级与天级均选出 `alpha=100`。

2.2　结果分析与可视化（15 分）

2.2.1　小时级回归结果

小时级指标见表2-1。Ridge 在 MAE、RMSE 和 R^2 上均优于普通线性回归，尤其 RMSE 从 18.835 下降到 8.793，说明正则化显著提升了线性体系在多源噪声数据上的稳健性。

图2-1显示预测点在低到中等盐度区间具有较稳定聚集，高误差主要出现在少量长尾样本，提示复杂工况时段仍是误差核心来源。

表 2-1　小时级回归指标对比（测试集）

模型	MAE	RMSE	R^2
Ridge(alpha=100.0)	3.6692	8.7930	0.0160
LinearRegression	3.8314	18.8352	-3.5151

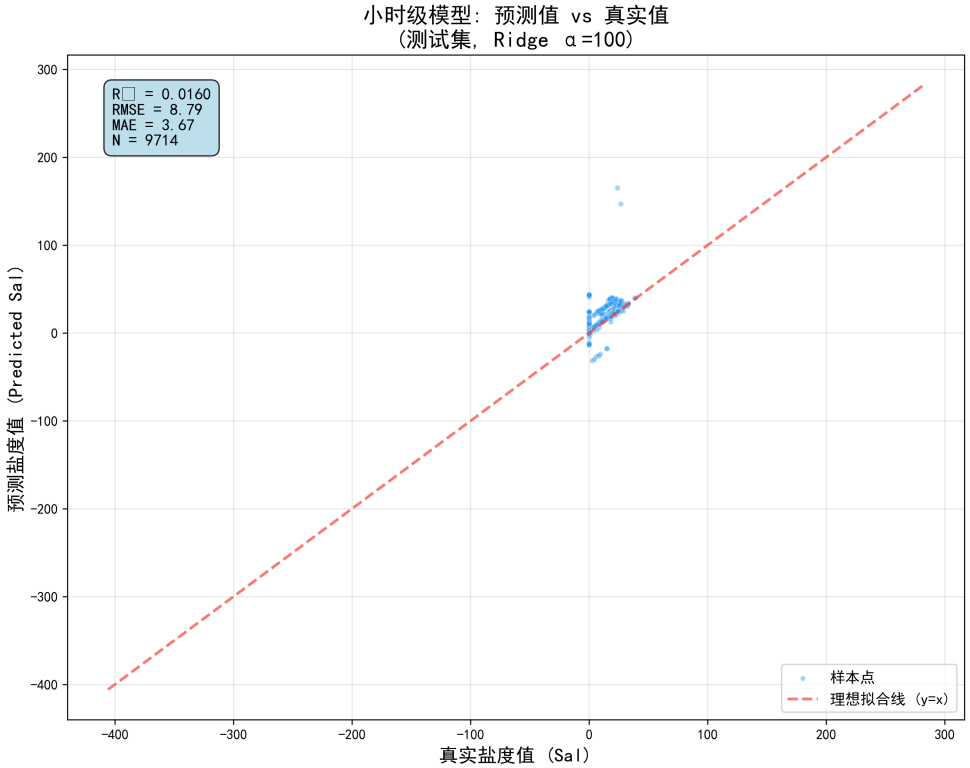


图 2-1　小时级最佳模型预测-真实散点图

2.2.2 天级回归结果

天级指标见表2-2。普通线性回归在该颗粒度下明显失稳，而 Ridge 仍保持可用误差水平。这表明天级聚合会同时带来噪声平滑与关键信息损失，需结合任务目标选择颗粒度，而非简单认为“聚合一定更好”。

表 2-2 天级回归指标对比（测试集）

模型	MAE	RMSE	R^2
Ridge(alpha=100.0)	6.0130	12.7383	-1.1766
LinearRegression	25.9324	267.1087	-956.0276

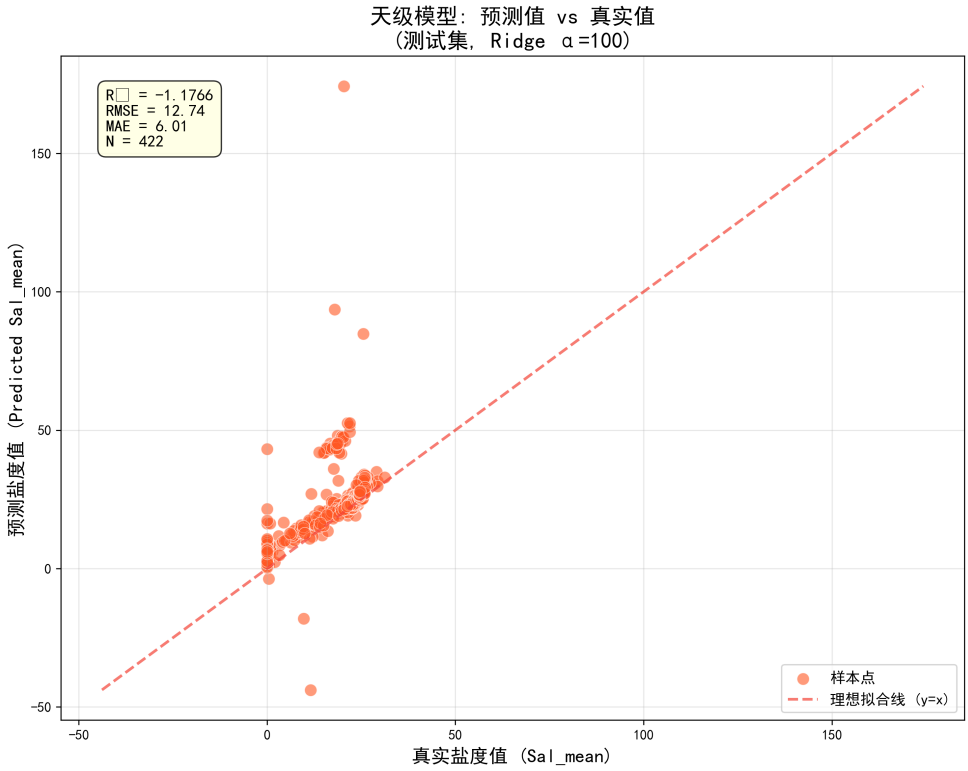


图 2-2 天级最佳模型预测-真实散点图

图2-2可见天级散点离散度明显高于小时级，与表2-2中的 RMSE 上升趋势一致。

2.2.3 聚类结果与状态解释

基于 `summary.json`，最优簇数为 2，轮廓系数为 0.2772，说明簇间分离度中等但存在有效结构差异。簇画像与样本分布见表2-3和表2-4。

表 2-3　聚类簇画像（天级特征均值）

cluster	Sal_mean	Temp_C_mean	pH_mean	Turb_NTU_mean	WSavg_mean	Abs_speed_mean
0	21.4016	21.8040	7.7272	106.4911	4.5332	19.6296
1	0.6752	19.8015	7.1011	5.7047	0.1515	34.5063

表 2-4　聚类样本分布统计

split	cluster 0	cluster 1
train	1596	110
test	397	39

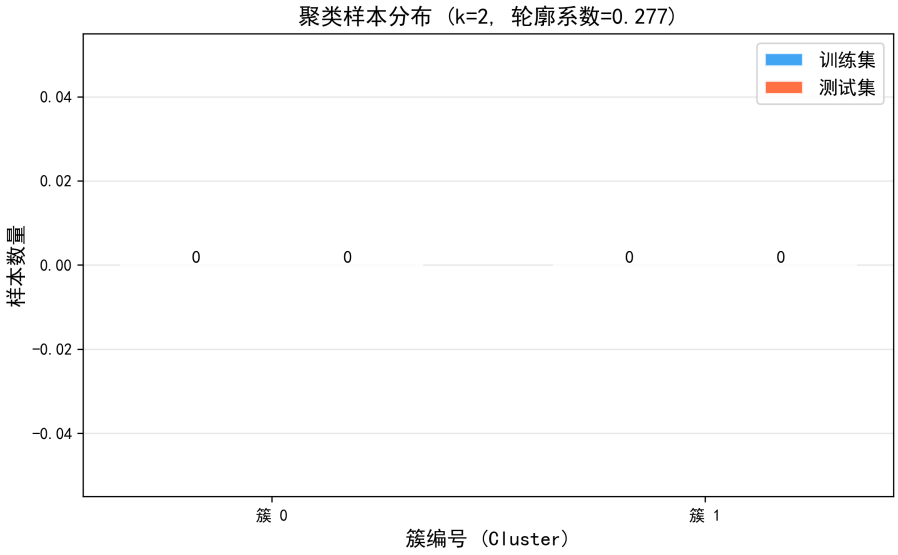


图 2-3　训练集与测试集聚类样本分布

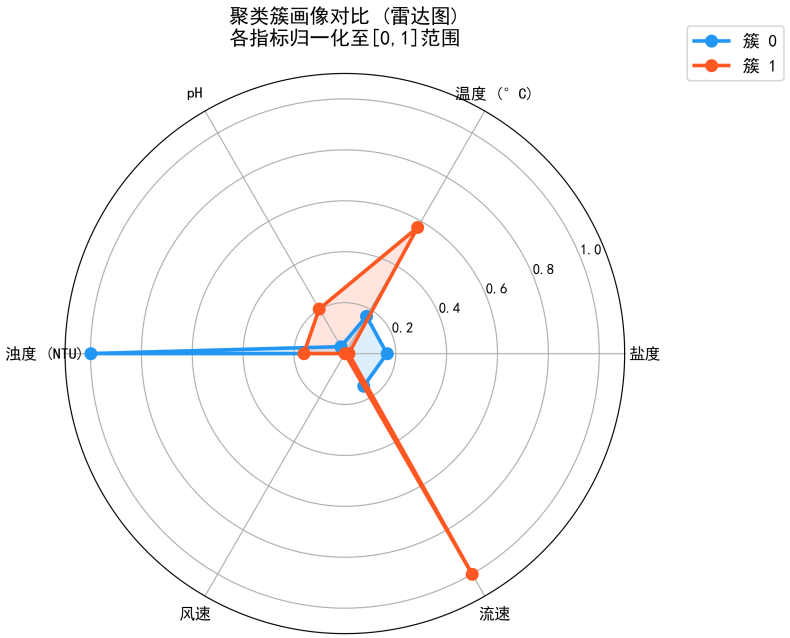


图 2-4　聚类簇画像雷达图

2.2.4　补充可视化

为增强可解释性，本文补充绘制了盐度时间序列与模型误差对比图，见图2-5与图2-6。这些图用于支撑“时段差异”和“模型稳健性差异”的结论。

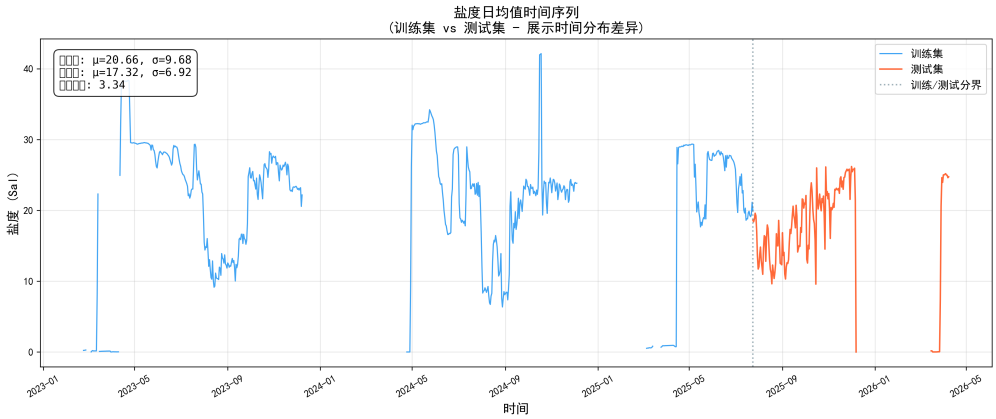


图 2-5　盐度时间序列折线图

2.2.5　本章小结

结果层面可以归纳为三点：

- Ridge 在小时级与天级均显著优于普通线性回归；
- 时间颗粒度对预测性能影响显著，小时级与天级不可互相替代；

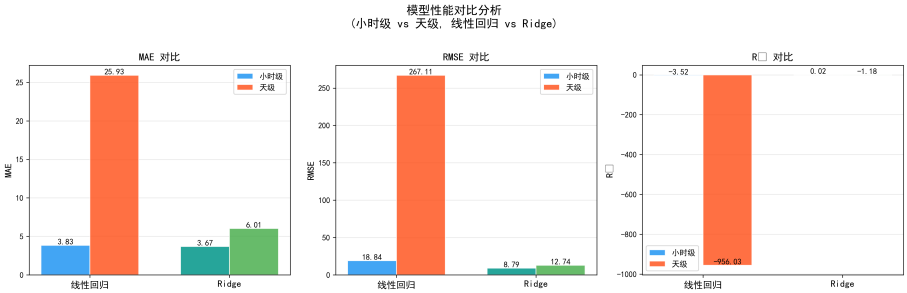


图 2-6　模型误差对比柱状图

- 聚类虽分离度中等，但能揭示环境状态异质性并辅助解释回归误差来源。

上述结论均可由 `outputs/*.csv,json` 与图2-1至图2-6对应复核。

第三章　讨论、结论与 AI 辅助说明

3.1　开放性思考与讨论（20 分）

3.1.1　跨时间分布漂移导致泛化压力增大

本实验采用历史训练、未来测试设置，真实暴露了时间漂移问题。即使训练阶段表现稳定，未来时段仍可能出现整体偏移，体现为 R^2 下降与长尾误差增加。该风险提示模型部署后可能发生性能衰减，后续可采用滚动窗口重训练、时间衰减加权与分季节建模进行缓解。

3.1.2　多源异步采样带来的信息不对齐

多源监测系统常存在采样周期差异、网络延迟与设备离线。当前采用锚表左连接与缺失填补保证了可训练性，但填补不能替代真实观测。后续可引入时间窗口匹配、缺失指示变量和按可用率分层建模，将“缺失模式”转化为可学习信号。

3.1.3　异常值中信号与噪声的边界不清

极端值可能来源于设备异常，也可能代表真实环境突变。静态物理阈值能去除明显非法值，但对边界样本仍缺乏情境化判断。下一步可结合站点历史分位数、相邻时段一致性和多源协同异常检测，提升清洗可信度。

3.1.4　线性模型的可解释性与表达上限

线性体系便于解释与教学复核，但在复杂非线性耦合场景下存在拟合上限。该限制并非纯粹缺点，它有助于区分“数据治理可改进问题”和“模型能力上限问题”，为后续迭代提供清晰方向。

3.1.5　多指标联合解读的重要性

在跨时段评估中，单看 R^2 容易产生偏差。MAE 反映平均误差，RMSE 对大误差更敏感，R^2 需结合分布漂移背景解读。本文坚持多指标联合解释，避免了“只报分数、不解释机制”的常见问题。

3.1.6 可复现性是实验质量的关键

本实验采用统一脚本、统一输出目录和固定证据文件（CSV/JSON/PNG），保证结论可追溯、可复核。这一工程化链路既提升了报告可信度，也为后续迭代提供了稳定基线。

3.2 结论（5 分）

本文基于真实海洋环境多源监测数据，完成了“盐度预测 + 环境状态解释”的完整实验流程。通过锚表融合、防泄漏控制、时间序列交叉验证与多指标联合评估，报告形成了从数据治理到模型评估、从数值预测到规律解释的闭环。

结果表明：Ridge 在小时级与天级均优于普通线性回归。小时级最佳模型达到 `MAE=3.6692`，`RMSE=8.7930`，天级最佳模型达到 `MAE=6.0130`，`RMSE=12.7383`；聚类最优为 `k=2`，轮廓系数 `0.2772`，揭示了可用于误差解释的状态异质性。

总体上，本实验在课程已学方法框架内实现了完整、可复核、可扩展的分析流程，满足课程实验报告提交要求。

3.3 AI 辅助分析与算法改进说明（附加分，最高 10 分）

本实验将 AI 用于“分析辅助”而非“结果替代”，主要体现在三个环节：

- 协助梳理实验章节结构，使报告从代码记录升级为问题驱动叙事；
- 协助比较和固化线性体系内改进策略，如锚表左连接、周期特征、Ridge 时序调参与防目标泄漏；
- 协助结果解释，将指标变化与数据机制关联，提升结论可读性。

需要说明的是，数据读取、清洗、训练、评估与可视化输出均由本地脚本完成；关键实验决策由本人根据课程要求与数据实际情况做出。AI 在本实验中的角色是提升效率和表达质量的工具，这一使用方式符合课程规范中“可使用 AI 辅助但需说明参与环节与价值”的要求[3]。

参考文献

［1］ 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016.

［2］ 天津大学课程组. 海洋环境数据分析实验课[Z]. 课程教学 PPT. 2026.

［3］ 天津大学课程组. 机器学习与深度学习-海洋环境监测实验报告撰写规范与给分标准-2025[Z]. 课程评分规范文档. 2025.

［4］ 李航. 统计学习方法[M]. 2 版. 北京: 清华大学出版社, 2019.

［5］ PEDREGOSA F, VAROQUAUX G, GRAMFORT A, et al. Scikit-learn: Machine Learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825-2830.

附　录

附录 A　复现实验命令

建议在项目根目录执行如下命令：

```
python 海洋环境数据/run_experiments.py
python 海洋环境数据/plot_figures.py
```

Listing 3.1　复现实验与图表生成命令

附录 B　主要输出文件说明

表 B-1　实验主要输出文件与用途

文件路径	说明
海洋环境数据/outputs/summary.json	样本规模、时间范围、最优模型和聚类摘要
海洋环境数据/outputs/metrics_hourly.csv	小时级回归指标对比
海洋环境数据/outputs/metrics_daily.csv	天级回归指标对比
海洋环境数据/outputs/cluster_profile.csv	聚类簇画像统计
海洋环境数据/outputs/cluster_counts.csv	聚类样本分布统计
海洋环境数据/figures/图 1_ 小时级预测散点图.png	小时级预测-真实散点图
海洋环境数据/figures/图 2_ 天级预测散点图.png	天级预测-真实散点图
海洋环境数据/figures/图 3_ 聚类样本分布柱状图.png	聚类样本分布柱状图
海洋环境数据/figures/图 4_ 聚类簇画像雷达图.png	聚类簇画像雷达图
海洋环境数据/figures/图 5_ 盐度时间序列折线图.png	盐度时间序列折线图
海洋环境数据/figures/图 6_ 模型误差对比柱状图.png	模型误差对比柱状图

附录 C　说明

正文中的指标、图表与本附录文件一一对应，可直接用于教师复核与后续模型迭代对比。